PROJECT RAPPRORT for kurs Matematisk Modelering MA1487 HT24

Olga Egorova, oleg22

Introduction

I projektet förväntas vi att plocka data från en open API, beskriva hämtade data och berbeta de med olika statistiska metoder. Datamängder för projektet hämtas från SMHI Open Data API Docs - Meteorological Observations. Detta API tillhandahåller meteorologiska data som beskriver väderförändringar på olika platser i Sverige. API:et erbjuder flera olika typer av mätningar, inklusive temperatur (parameter 1) och relativ luftfuktighet (parameter 6). Dessa parametrar kan användas för att, till exempel, förstå klimatförhållanden och variationer över tid.

För projektet ville jag hämta begränsad mängd av data. Eftersom temperaturs och relativt luftfuktighet mäts varje timme, data från sista tre dygn ska innehålla 72 mätningar. Det mängd av data är oversiktligt och tillräckligt stor för vlera statistiska metoder. Därför välde jag dessa parametrar för analys. I arbete används data från tre meteorologiska stationer: Halmstad flygplats, Uppsala Flygplats och Umeå Flygplats. Stationer välds eftersom båda välda parametrar finns att hämta i API. Flera andra stationer hade inte data för dessa parametrar.

Temperaturen mäts i grader Celsius (°C), medan relativ luftfuktighet anges i procent (%). Genom att använda dessa data kan jag utföra olika typer av statistiska analyser, inklusive visualiseringar av frekvensfördelningar, beräkningar av medelvärden och standardavvikelser, samt jämförelser mellan stationer och parametrar. Detta arbete syftar till att demonstrera hur statistiska metoder kan användas för att bearbeta och tolka meteorologiska data.

Uppgift 1. Databeskrivning

All kod som jag använder för att hämta och bearbeta data finns i GitHub. För att hämta en ny dataset, skaffa alla tabeller och figurer tillräckligt att använda fill ´ALL_CODE.py´ Datamängder plockas med följande kod:

```
import json

# This part i inactivated because i am working with downloaded data
# Dowloads data from three stations and for two parameters
for key in PARAMS.keys():
    for station, id in STATIONS.items():
        data_url = (f'https://opendata-download-metobs.smhi.se'
                    f'/api/version/1.0/parameter/'
                    f'{key}/station/{id}/period/{PERIOD}/data.json')
```

```
            response = requests.get(data_url)
            response.raise_for_status()  # Check if the request succeeded

            result = json.loads(response.content)
            save_path = f'data/{id}_{key}.json'
            with open(save_path, "w", encoding="utf-8") as file:
                json.dump(result, file, indent=4, ensure_ascii=False)
```

Som resultat genereras en JSON-fil för varje kombination av station och parameter. Varje fil innehåller över 2500 mätpunkter, vilket ger en omfattande datamängd för analys. För statistisk bearbetning används data från de senaste 72 timmarna. Urvalet av data görs med hjälp av följande kod:

```
import datetime
import json
import pytz
import numpy as np

# variables
STATIONS = {
            'Halmstad flygplats': 62410,
            'Uppsala Flygplats': 97530,
            'Umeå Flygplats': 140480
            }
# parameters to download (parameter_id:parameter_name)
PARAMS = {1:["TEMPERATUR", "°C"], 6:["LUFTFUKTIGHET", "%"]}
# Extract the required period (three days) from downloaded data
measured_points = 72  # Number of points to include
three_days = {}
data_rows = []

# Process data for each parameter and station
for param_id, parameter in PARAMS.items():
    three_d_station = {}
    for name, station_id in STATIONS.items():
        file_path = f'data/{station_id}_{param_id}.json'
        with open(file_path, 'r') as file:
            data = json.load(file)

        # Sort data by timestamp and select the last N points
        sorted_data = sorted(
            data.get("value", []),
            key=lambda x: datetime.fromtimestamp(x["date"] / 1000,
            tz=pytz.timezone("Europe/Stockholm"))
        )[-measured_points:]
```

```
            # Prepare station data and append rows for further processing
            stat_set = {}
            for item in sorted_data:
                check = item['quality'] in ['G', 'Y']
                new_value = float(item['value']) if check else np.nan
                stat_set[item['date']] = new_value
                data_rows.append({
                    'time': datetime.fromtimestamp(item['date'] / 1000,
                            tz=pytz.timezone("Europe/Stockholm")),
                    'station_name': name,
                    'parameter': PARAMS[param_id][0],
                    'value': new_value
                })
            three_d_station[name] = stat_set
        three_days[param_id] = three_d_station
```

Det skaffas två objekt med samma innhåll: 1. ´tree-days´ - En nästlad ordbok (dictionary) som innehåller filtrerad och sorterad data för de senaste 72 timmarna för varje parameter och station. Strukturen ser ut så här:

```
{
    param_id: {  # Parameterens ID
        station_name: {  # Stationens namn
            timestamp: värde,  # Tidsstämpel och tillhörande mätvärde
            ...
        },
        ...
    },
    ...
}
```

Nycklar: param_id (parameter-ID) och station_name (stationens namn). Värden: För varje station skapas en ordbok där nyckeln är en tidsstämpel och värdet är ett numeriskt mätvärde (eller numpy.nan om kvaliteten inte är godkänd). Det objekt används i flesta fall. 2. ´data_rows‘ - En lista med rader där varje rad är en ordbok med information om en specifik mätpunkt. Strukturen ser ut så här: [{ ‘time’: datetime-objekt, # Tidsstämpel som datetime-objekt ‘station_name’: ‘stationens namn’, # Namn på mätstationen ‘parameter’: ‘parameterens namn’, # Parameterns namn (t.ex. temperatur eller luftfuktighet) ‘value’: numeriskt värde # Mätvärde eller numpy.nan }, …] Sista objektet är lättare att omvandla till pandas objekt. För att lättare operera med data jag skaffar också kombinerad objekt ´df_three´.

```
import utils # some funktionalitet

# Convert the list of dictionaries into a pandas DataFrame objekt
df_three = pd.DataFrame(data_rows)
df_three.columns.str.replace(' ', '\n')
```

```
# save to markdown file to be able sow in the presentation
utils.save_to_mdfile(df_three, 'dataframe.md', 'statistics')
```

Urval av hämtade datamängd presenteras i Tabel 1. Fullständigt tabell finns på GitHub

Tabel 1. Sammansätta data

	time	station_name	parameter	value
0	2024-12-15 18:00:00+01:00	Halmstad flygplats	TEMPERATUR	7.8
1	2024-12-15 19:00:00+01:00	Halmstad flygplats	TEMPERATUR	8.1
132	2024-12-18 06:00:00+01:00	Uppsala Flygplats	TEMPERATUR	-3.7
133	2024-12-18 07:00:00+01:00	Uppsala Flygplats	TEMPERATUR	-3.2
214	2024-12-18 16:00:00+01:00	Umeå Flygplats	TEMPERATUR	-3.4
215	2024-12-18 17:00:00+01:00	Umeå Flygplats	TEMPERATUR	-3.1
216	2024-12-15 18:00:00+01:00	Halmstad flygplats	LUFTFUKTIGHET	98
217	2024-12-15 19:00:00+01:00	Halmstad flygplats	LUFTFUKTIGHET	95
429	2024-12-18 15:00:00+01:00	Umeå Flygplats	LUFTFUKTIGHET	95
430	2024-12-18 16:00:00+01:00	Umeå Flygplats	LUFTFUKTIGHET	95
431	2024-12-18 17:00:00+01:00	Umeå Flygplats	LUFTFUKTIGHET	96

För att testa om vissa tidpunkter pa en av stationer saknar av mätningar används följande kode:

```
# Count NaN values per station_name and parameter
nan_counts = df_three.groupby(['station_name', 'parameter'])['value'].apply(
                                    lambda x: x.isna().sum()
                                    ).reset_index()


# Give name for columns
nan_counts.columns = ['station_name', 'parameter', 'Missing values']
utils.save_to_mdfile(nan_counts, "nan_counts.md", "statistics")
```

Resultat visar att inga mätningar saknas (Tabel 2.):

Tabel 2. Missade data för alla parameter:

	station_name	parameter	Missing values
0	Halmstad flygplats	LUFTFUKTIGHET	0
1	Halmstad flygplats	TEMPERATUR	0
2	Umeå Flygplats	LUFTFUKTIGHET	0
3	Umeå Flygplats	TEMPERATUR	0
4	Uppsala Flygplats	LUFTFUKTIGHET	0
5	Uppsala Flygplats	TEMPERATUR	0

Uppgift 2. Beskrivande statistik

För att snabbt räkna ut statistiska egenskaper jag använder describe() metod fär pandas objekt.

```
descriptive_stats = df_three.
        groupby(['station_name', 'parameter'])['value'].describe()
```

Resultat presenterad i Tabel 3:

Tabell 3. Beskrivande statistik för alla stationer och parametrar

staion, parameter, enheter	count	mean	std	min	25%	50%	75%	max
Halmstad flygplats, LUFTFUKTIGHET, %	72	91.47	5.98	75	90	93	96	99
Halmstad flygplats, TEMPERATUR °C	72	6.91	0.93	4.4	6.38	7	7.43	8.9
Umeå Flygplats, LUFTFUKTIGHET, %	72	88.38	4.1	81	85	88	91.25	96
Umeå Flygplats, TEMPERATUR, °C	72	- 10.61	5.68	- 20.4	- 15.82	- 10.05	- 5.38	-1.3
Uppsala Flygplats, LUFTFUKTIGHET, %	72	78.01	14.14	57	64	77.5	87.25	100
Uppsala Flygplats, TEMPERATUR, °C	72	1.27	2.48	-4.7	0.18	1.9	2.72	6.6

Tabellen att alla stationer har 72 mätningspunkter för båda parameter. Medelvärde är oftast inte avvikar mycket från medianen med undentag för temperatur i Umeå. Första och tredje kvartiler avstar ganska lika mycket

från median, men minimala och maksimala värde avstar inte lika mycket från median.

Det är svårt att säga om data är normalfördelat enbart från resultater av tabellen. Jag skaffar därför plottar som visar hur data fördelade.

Beskrivande statistik kan visualiseras med hjälp av ladogrammar, som visar medelvärde, kvariler, 95% spridningen och avvikande värde i urvalet.

Uppgift 3. Beskrivande plottar

Följande kode skaffar ladogrammer för varje station ohc parameter. Jag välde att göra Shapiro-Wilk test och visualisera resultat på ladogrammer, (Figur 2.). Shapiro-Wilk test en av mest användda tester för att jamföra urvalet med normalfordelninen. p-värde mindre än 5% tillåter säga att det är ossannolikt att urvalets data normalfördelade.

```
# Arrayer to itirate through
stations = df_three['station_name'].unique()
parameters = df_three['parameter'].unique()

# Set up the figure
fig, axes = plt.subplots(2, 3, figsize=(12, 4 * 2))  # 2 rows, 3 columns

# Array to save reultats of the Shapiro-Wilk test
ShapiroW = []
# Loop over stations and parameters
for i, parameter in enumerate(parameters):
    for j, station in enumerate(stations):
        # check stations name
        condition_station = df_three['station_name'] == station
        # check parameter
        condition_parameter = df_three['parameter'] == parameter
        # mask to filter
        mask = condition_station & condition_parameter
        data_filtered = df_three[mask]

        # Perform Shwpiro-Wilk normality test
        stat, p_value = sci.shapiro(data_filtered['value'])
        ShapiroW.append({
            'Station': station,
            'Parameter': parameter,
            'Shapiro-Wilk Statistic': round(stat, 5),
            'P-value': round(p_value, 5),
            'Normal Distribution (p > 0.05)': 'Yes' if p_value > 0.05 else 'No'
        })
```

```
            ax = axes[i, j]

            # the boxplot
            sns.boxplot(
                ax=ax,
                data=data_filtered,
                x='station_name',  # Same station on x-axis
                y='value',
                palette=[COLORS[j]],  # Assign unique color for the station
                width=0.3,
                dodge=False
            )
            # y-lables
            ax.set_ylabel((f'{parameter}'
                           f'{'°C' if parameter == 'TEMPERATUR' else '%'}'),
                           fontsize=8
                        )
            # Remove the x-axis label
            ax.set_xlabel('')

            # Annotate p-value on the plot
            ax.text(
                0.8,
                0.13,
                (f'p={p_value:.5f}'),
                transform=ax.transAxes,
                fontsize=10,
                ha='center',
                color='red' if p_value < 0.05 else 'black'
            )
    plt.suptitle("Databeskrivning med ladogrammar", fontsize=16)

    # Adjust layout to make space for the title
    plt.tight_layout(rect=[0, 0, 1, 0.95])

    plt.savefig('https://raw.githubusercontent.com/OlganeOlga/MathMod/master/img/box_plot/al
    plt.show()
```

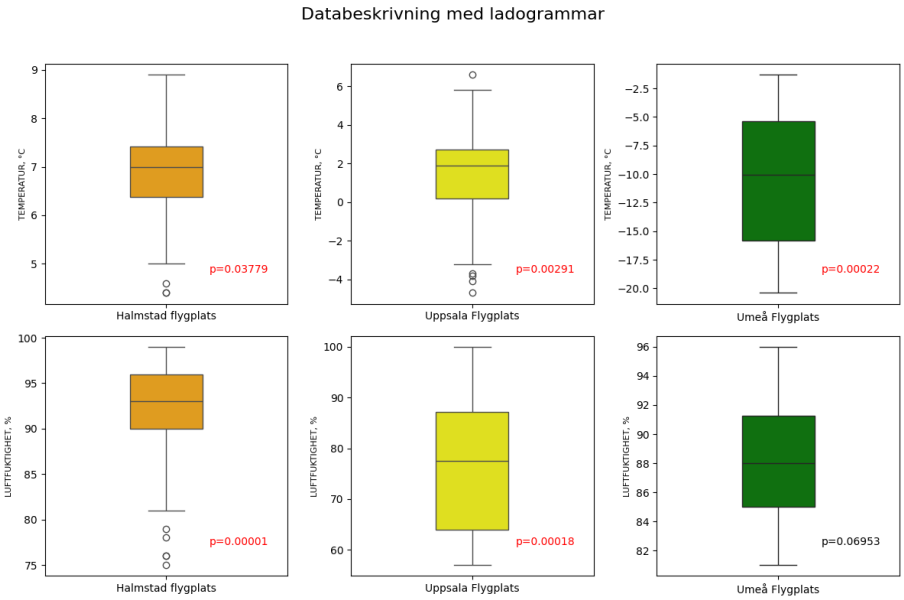

Figur 1.

Förklaring till Figur 2. Figuren visar boxplottar för olika stationer och parametrar. De parametrar som visas och respektiva stationer skriven under varje subplot. Motsvarande enheter anges med etiketter till y-axes. Boxplottarna visar fördelningen av värden för varje station, där den horisontal linjen representerar medianen, boxarna visar det interkvartila intervallet (IQR) och morrhåren sträcker sig till minimi- och maximivärdena inom 1,5 * IQR. Små sirklar visar avvikande värde. För varje boxplott anges ett resultat från Shapiro-Wilk-testetm, den hjälper att bedöma om data följer en normalfördelning. Ett p-värde under 0,05 indikerar att data inte följer en normalfördelning, och detta markeras med rött i diagrammet.

Tabell 4. Resultater av Shapiro-Wilk test

Station	Parameter	Shapiro-Wilk Statistic	P-value	Normal Distribution (p > 0.05)
Halmstad flygplats	LUFTFUKTIGHET	0.884	0	No
Halmstad flygplats	TEMPERATUR	0.964	0.038	No
Umeå Flygplats	LUFTFUKTIGHET	0.969	0.07	Yes
Umeå Flygplats	TEMPERATUR	0.92	0	No

Station	Parameter	Shapiro-Wilk Statistic	P-value	Normal Distribution ($p > 0.05$)
Uppsala Flygplats	LUFTFUKTIGHET	0.918	0	No
Uppsala Flygplats	TEMPERATUR	0.944	0.003	No

Med dessa plottar och Shapiro-Wilk test testar jag nulhypotes: att data är noirmalfördelad. Ldogrammar och Shapiro-Wilk test för normality tillåtar förkasta nulhypotes om att temperatur spridning är normal fördelad. Sannolikheten att nulhypotes stämmer är mindre än 5% och därmed för alla tre platsar och därmed är sannolikhet för typ II fel (att felaktigt förkasta null hupotes) är ganska liten. Samma påstående stämmer för relativt lyft fuktighet med undantag för relativt luftfuktighet i Umeå flygplats, där sannolikhet att null hypotes stämmer är mera än 5%, nämlgen 7%.

Fördelning av data i urvalet kan visualiseras även med stapeldiagram. Figur med stapeldiagammar skapas med följande koden:

```
# initiate figure
plt.figure(figsize=(8, 6))

# Prepare the custom blue square legend handle
text = 'Blue color shows samples distribution'
blue_square = Line2D([0], [0],
                     marker='s',
                     color='w',
                     markerfacecolor='blue',
                     markersize=8,
                     label=text
                     )

# Prepare the legend for the normal distribution
normal_dist_line = Line2D([0], [0],
                          color='orange',
                          lw=2,
                          label="Normal Distribution"
                          )

# variable to chose what norm dist line vill be shown in the legend
normal_dist_added = False
# Iterate through all stations and parameters
for i, station in enumerate(stations):
    for j, parameter in enumerate(parameters):
        condition_station = df_three['station_name'] == station
```

```
            condition_parameter = df_three['parameter'] == parameter
            mask = condition_station & condition_parameter
            # filter data for each station and parameter
            data = df_three[mask]

            # Subplot indexering: 3 rows for 3 stations and 2 columns for 2 parameters
            plt.subplot(3, 2, i * len(parameters) + j + 1)

            sns.histplot(data['value'],
                         kde=True,
                         bins=24,
                         color="blue",
                         edgecolor="black")

            # Calculate the mean and standard deviation
            mean = data['value'].mean()
            std_dev = data['value'].std()

            # Generate x values for normal distribution (range around the data's values)
            x = np.linspace(data['value'].min(), data['value'].max(), 100)

            # Calculate the normal distribution values (PDF)
            y = sci.norm.pdf(x, mean, std_dev)
            # Add normal distribution with te same parameters to the subplot
            plt.plot(x, y * len(data) * (x[1] - x[0]), color='orange')

            # add title and axes
            plt.title(f"{station}", fontsize=10)
            # Conditionally set the xlabel depending on the parameter
            if parameter == 'TEMPERATUR':
                plt.xlabel(f"{parameter.lower()} (°C)")
            else:
                plt.xlabel(f"{parameter.lower()} (%)")

            plt.ylabel("Frekvens")
    # Create a global legend outside the subplots (top)
    fig = plt.gcf()  # Get the current figure

    fig.legend(handles=[blue_square,
                normal_dist_line],
                loc='upper center',
                bbox_to_anchor=(0.5, 0.99),
                ncol=2,
                fontsize='small'
                )
```

```
plt.tight_layout()
plt.subplots_adjust(top=0.85)
# Save and show the plot
plt.savefig("img/frekvenser/alla.png")
```

Grafiska fördelningar visas i Figur 2.

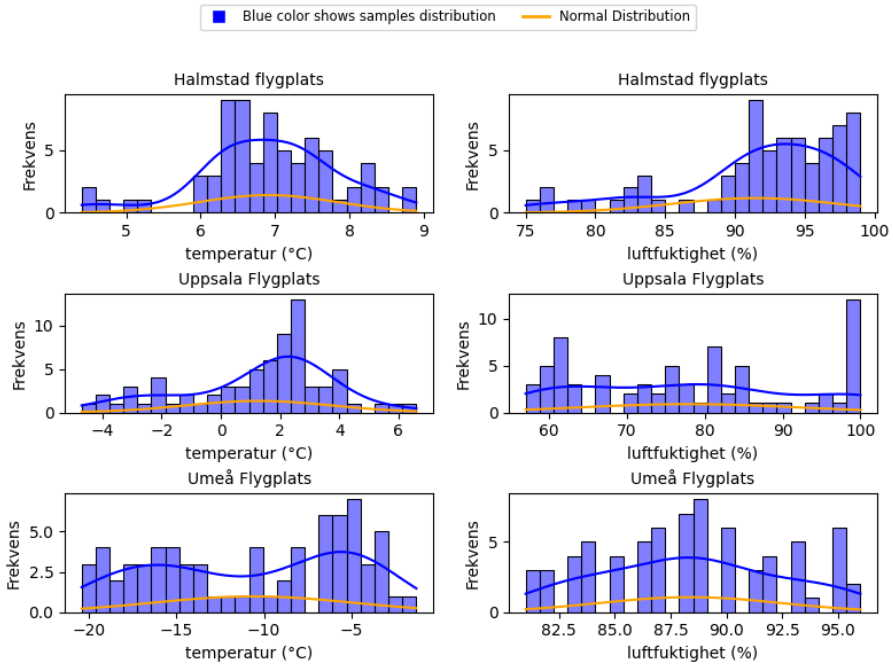

Förklaring till Figur 2. Den här figuren visualiserar frekvensfördelningen av temperatur- och relativ luftfuktighetsdata från flera stationer i Sverige, inklusive Halmstad Flygplats, Uppsala Flygplats och Umeå Flygplats. Fördelningen visas som histogram med Kernel Density Estimation (KDE), och varje subplot motsvarar en kombination av station och parameter.De blå staplarna representerar frekvensfördelningen av mätningarna, där varje stapel representerar ett specifikt värdeintervall. Blå linjän visar Kernel density estimation, eller den uppskattade sannolikhetsdensiteten för mätvärdena. Normalfördelningskurvan är en orange linje. Denna kurva beräknas med hjälp av medelvärdet och standardavvikelsen för värdena i datasetet för varje station och parameter. Normalfördelningen läggs till för att visuellt jämföra hur den faktiska datadistributionen överensstämmer med den teoretiska normalfördelningen.

Figurer 1 och 2 visar att spridningen i alla datamängder avviker från Normalspridningen. Shapiro-Wilk dock säger att dataspridning av relativt luftfuktighet i Umeå närmar sig mest till normalt. Stapelldiagrammar visar också att rela-

tivt luftfuktighet förändras inte likadant med temperaturförändring vid varje station. Här ifrån tar jag slutsatsen att det är inte korrekt att utföra statistiska tester på sammansätta data från alla stationer.

Q__Q plottar

Det finns ett annat sät att visualisera avvikelse från eller liknande till normalfördelning, nämligen kvantil_kvantil plot(1). Q-Q plottar skaffas ed förljande koden:

```
fig, axes = plt.subplots(2, 3, figsize=(10, 3 * 2))
# Loopa through all stations and parameters
for i, station in enumerate(stations):
    for j, parameter in enumerate(parameters):
        condition_station = df_three['station_name'] == station
        condition_parameter = df_three['parameter'] == parameter
        mask = condition_station & condition_parameter
        # Filter for station and oarameter
        data = df_three[mask]
        numeric_data = data['value'].dropna()
        # Create Q_Q plots
        ax = axes[j, i]
        sci.probplot(numeric_data, dist="norm", plot=ax)
        l_unit = 'temperatur, °C' if parameter == 'TEMPERATUR' else 'humidity, %'
        ax.set_ylabel(l_unit, fontsize=8)
        # Add titel
        ax.set_title(f"Q-Q plot: {station} - {parameter}", fontsize=8)
        ax.get_lines()[1].set_color('red')  # Give lene for the
plt.tight_layout()
plt.savefig('https://raw.githubusercontent.com/OlganeOlga/MathMod/master/img/q_q_plot/al
plt.close()
```

REsultat visas på Figur 3.

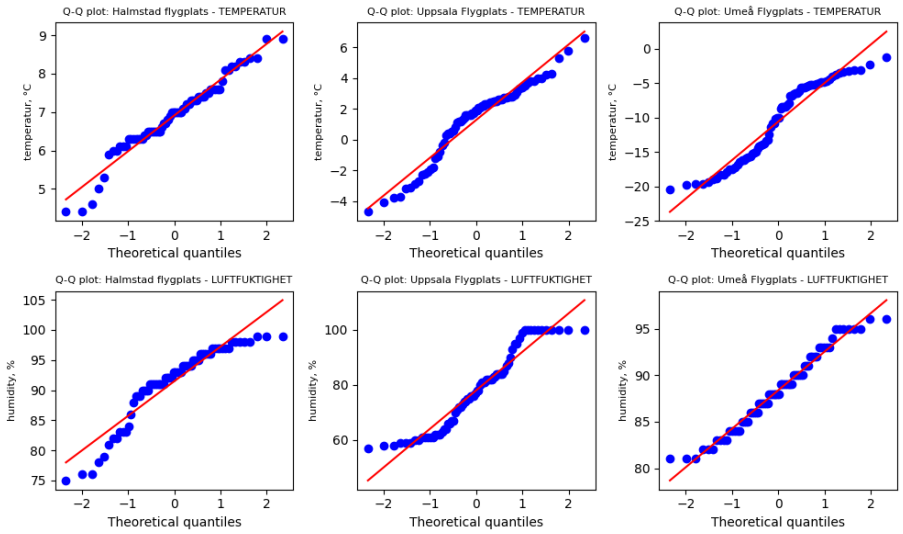

Figur 3.

Förklaring av Quantile-Quantile fördelning plottar På plottar jämförs dataset från olika stationer och parametrar mot den teoretiska normalfördelningen. En Q-Q plot (Quantile-Quantile plot) jämför de empiriska kvantilerna från den faktiska datan med de teoretiska kvantilerna från en normalfördelning. Syftet med denna figur är att visuellt bedöma hur väl datan följer en normalfördelning. Varje plot visar fördelningen av en dataset. I På X-axeln visas normafördelnings kvantiler, på Y-axeln visas kvantiler från respektiv datamängd (Tabel 3a[b][### Tabel 3b])

Tolkning av figuren: - **Om punkterna ligger nära en rak linje**: Detta tyder på att datan är nära en normalfördelning. - **Om punkterna avviker från linjen**: - **Om punkterna böjer sig uppåt vid svansarna**: Detta kan indikera att datan har för mycket extrema värden, vilket tyder på en tyngre svans än normalfördelningen (t.ex. en t-fördelning). - **Om punkterna böjer sig nedåt vid svansarna**: Detta kan tyda på att datan har för få extrema värden och inte har lika många extremvärden som en normalfördelning. - **Om punkterna är ojämnt fördelade eller böjer sig i mitten**: Detta kan indikera en snedvridning (skewness) i datan, vilket innebär att den inte är symmetrisk.

Denna typ av figur används för att snabbt bedöma om datan följer en normalfördelning, vilket kan vara användbart i statistiska tester eller när du ska välja lämpliga modeller för analysen.

Liksom tidigare testar visar figur att närmast till normalfördelningen är data från relativt luftfuktighet i Umeå flygplats.

Jag försökte ta bort mest avvikande värde från Umeå dataset (i example kod kastas de 5 högsta och 2 lagsta värde) för att se om det hjälper att nå normalfördelning.

Här är exampel kod:

```
# Get data with removed titestips for the lowers temperatur
name = 'Umeå Flygplats'
# Filter data for the specific station
station_data = df_three[df_three['station_name'] == name]

# Number of lowest temperature data points to remove
to_remove = 4
changed_by ='TEMPERATUR'
# Find the rows with the lowest temperature values
param_data = station_data[station_data['parameter'] == changed_by]
# Rows with the lowest parparameter values
lowest_param = param_data.nsmallest(to_remove, 'value')
#all_param = lowest_param.nlargest(1, 'value')
all_param = lowest_param
# Extract the timestamps as a list

all_param_timestamps = lowest_param['time'].tolist()
# Filter out rows with the lowest parameter values timestamps across all parameters
filtered_data = station_data[~station_data['time'].isin(all_param_timestamps)]

# Plot the filtered data
fig, axes = plt.subplots(1, 2, figsize=(8, 4))
for i, value in enumerate(PARAMS.values()):
    ax = axes[i]
    # Filter the parameter-specific data
    param_data = filtered_data[filtered_data['parameter'] == value[0]]
    stat, prob = sci.shapiro(param_data['value'])
    numeric_data = param_data['value'].dropna()

    # Generate Q-Q plot
    sci.probplot(numeric_data, dist="norm", plot=ax)
    lable_unit = 'temperatur, °C' if parameter == 'TEMPERATUR' else 'humidity, %'
    ax.set_ylabel(lable_unit, fontsize=8)
    ax.set_xlabel("teoretiska quantiler")
    axes[i].text(0.1,
                 0.9,
                 (f'Shapiro_Wilk test: statistik={stat:.2f},\n'
                 f'sannolikhet för normalspridning={prob:.2f}'),
                 color="red", fontsize=5,
                 transform=ax.transAxes,
                 verticalalignment='top',
                 bbox=dict(facecolor='white', alpha=0.5)
            )
    # Clear the title
```

```
    ax.set_title(value[0].lower())
    # Add line
    ax.get_lines()[1].set_color('red')
plot_title = (f'Q-Q plot: {name} utan {to_remove} tidpunkter\n'
              f'med de lägsta {changed_by.lower()} värder')
plt.suptitle(plot_title, fontsize=12)
plt.tight_layout()
cleaned_name = re.sub("(?i)" + re.escape("flygplats"), "", name)
dirs = 'https://raw.githubusercontent.com/OlganeOlga/MathMod/master/img/q_q_plot/'
l_changed = changed_by.lower()
file_name = f'{dirs}/{cleaned_name}_{l_changed}_min_{to_remove}_outliers.png'
plt.savefig(file_name)
plt.show()
plt.close()
```

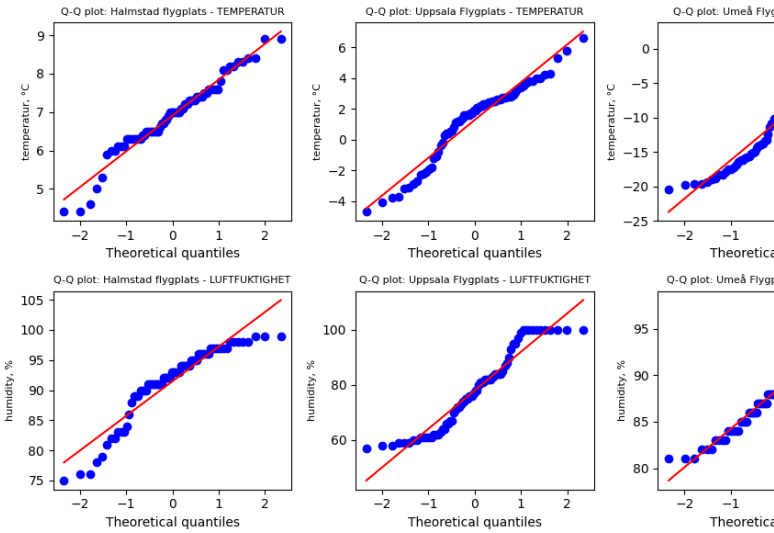

I Figur 3a visas resultat. #### Figur 3a.

Figur 3a visar om extrema värde tas bort, då närmar dataset sig normalfördelningen. Jag tycker dock att fördelninen förändras inte tillräckligt mycket. Därför fortätter jag analysera öförändrade dataset.

Uppgift 4: Linjär regression

För att ser med vilka data ska jag arbeta vill jag först titta på hur data korrelerrar med varandra. Därför skaffar jag några plottar, som visas på Figur 4.

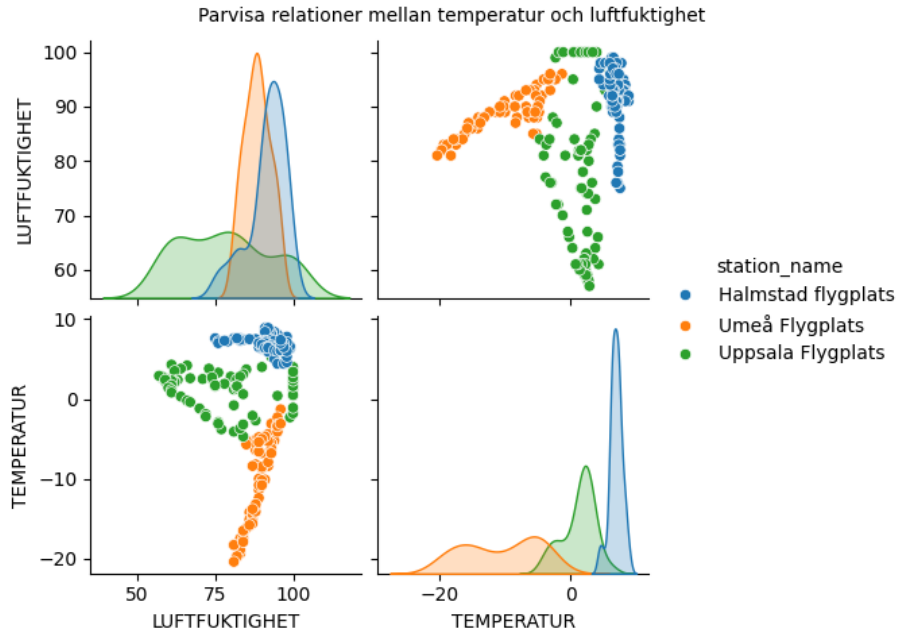

Figur 4a.
Figuren visar att temperatur och luftfuktighet i Umeå flugplats korrelerar, men det kan inte sägas att luftfuktighet och temperatur korrelerar i två andra stationer. Plot var skaffat med förljande kod:

```
# Pivote three_days
pivote_df = df_three.pivot_table(index=['time', 'station_name'],
                                 columns='parameter',
                                 values='value').reset_index()


# create paired plot
sns.pairplot(pivote_df, hue='station_name')
plt.subplots_adjust(top=0.9)
plt.suptitle("Parvisa relationer mellan temperatur och luftfuktighet",
             fontsize=10,
             y=0.95)
plt.savefig("img/correlation/param_param.png")
plt.show()
plt.close()
```

Jag skaffar även ett annat plot, som visar mera detaljer:

```
# Pairplot
fig = sns.pairplot(combined_data, height=1.8, diag_kind='kde')
# Adjust igont size and axis
for ax in fig.axes.flatten():
    # Get current x and y axis labels
```

```
        xlabel = ax.get_xlabel()
        ylabel = ax.get_ylabel()

        # Remove "flygplats" (case-insensitive)
        xlabel = re.sub(r'(?i)flygplats', '', xlabel).strip()
        # Replace "TEMPERATUR_" with "TEMP_"
        xlabel = xlabel.replace("TEMPERATUR_", "°C, TEMP_").strip()
        # Replace "LUFTFUKTIGHET_" with "FUKT_"
        xlabel = xlabel.replace("LUFTFUKTIGHET_", "%, FUKT_").strip()

        # Remove "flygplats" (case-insensitive)
        ylabel = re.sub(r'(?i)flygplats', '', ylabel).strip()
        # Replace "TEMPERATUR_" with "TEMP_"
        ylabel = ylabel.replace("TEMPERATUR_", "°C, TEMP_").strip()
        # Replace "LUFTFUKTIGHET_" with "FUKT_"
        ylabel = ylabel.replace("LUFTFUKTIGHET_", "%, FUKT_").strip()

        # Set the modified labels with font size
        ax.set_xlabel(xlabel, fontsize=6)
        ax.set_ylabel(ylabel, fontsize=6)

        ax.set_ylabel(ylabel.replace("LUFTFUKTIGHET_", "%, FUKT_").strip(), fontsize=6)

        # Set font size for tick labels
        ax.tick_params(axis='x', labelsize=5)
        ax.tick_params(axis='y', labelsize=5)

plt.suptitle("Pairwise Relationships for Parameters and Stations",
    y=0.99,
    fontsize=16)
plt.subplots_adjust(hspace=0.2, wspace=0.2, top=0.9)
plt.savefig('https://raw.githubusercontent.com/OlganeOlga/MathMod/master/img/correlatio
plt.show()
plt.close()
```

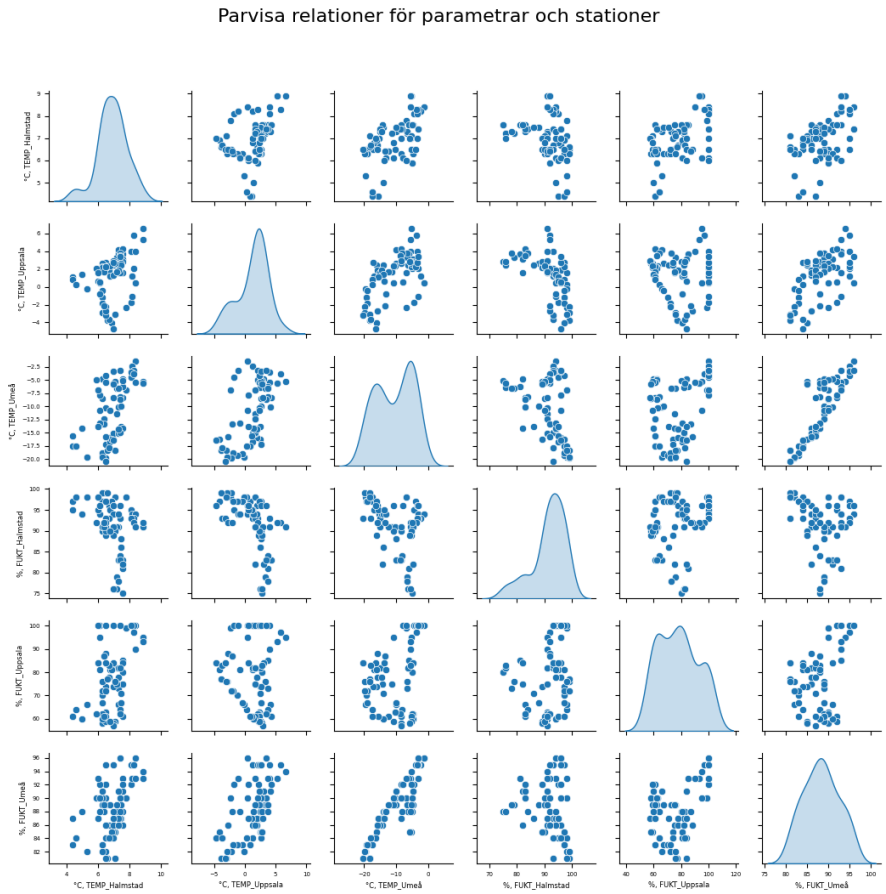

Figur 4b.
Detta plot visar igen, att det kan finnas direkt samband mellan relativt luftfuktighet och temperatur i Umeå. Jag skapar också matris som visar hur korrelerrar en parameter från en station med alla andra parameter-station kombinationer.

```
# Calculate the correlation matrix
correlation_matrix = combined_data.corr()

# Plot the heatmap
plt.figure(figsize=(12, 10))
ax = sns.heatmap(
    correlation_matrix,
    annot=True,  # Avoid cluttering with too many annotations
    cmap=LinearSegmentedColormap.from_list("CustomCmap", COLORS, N=256),
    cbar=True
)
# Adjust font sizes for station names
```

```
ax.tick_params(axis='x', labelsize=8)
ax.tick_params(axis='y', labelsize=8)
plt.title("Korrelationsmatris för alla parametrar och stationer", fontsize=14)
plt.tight_layout()
plt.savefig('https://raw.githubusercontent.com/OlganeOlga/MathMod/master/img/correlation
plt.show()
plt.close()
```

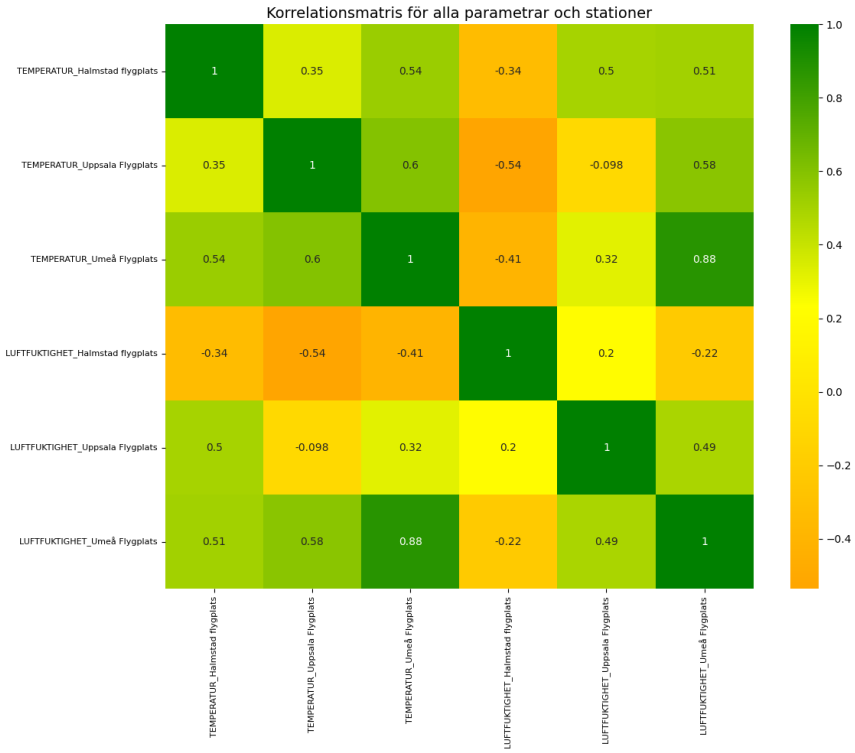

Figur 4c.

Förklaring till Figur 4c. I figur visas korrelations koeffitienter mellan olika dataset. På axlar visas olika parameter-station kombiantioner. Samma kombinatiner visas på båda axlarna. Korrelationskoefitientar mellan parar visas med text i färgade kvadrater. Färgskala visas till höger. Färgskalan hjälper till visuelt bedömningen.

Korrelationmatrisen visar samma som två figurer innan (Figur 4a och Figur 4b).Ttydlig korrelation finns bara mellan relativt luftfuktighet och temperatur i Umeå flugplats. Därför väljer jag att utförska samband mellan relativt luftfuktighet och temperatur bara i Umeå vidare.

Jag skaffar regressions modell med hjälp av maskinlearning. 50% av data används som tanings dataset de resterande 50% används som testdataset.

```
# Get training ang testing datasets
fraktion = 0.5
train = combined_data.sample(frac=fraktion, random_state=1)
test = combined_data.drop(train.index)

# # Extract X (independent variable) and y (dependent variable) from the dataframe
# Title for the plot
X_train = train[column_name1].values.reshape(-1, 1)
y_train = train[column_name2].values
X_test = test[column_name1].values.reshape(-1, 1)
y_test = test[column_name2].values


model = LinearRegression().fit(X_train, y_train)
pred = model.predict(X_test)

# Räkna ut MSE
mse = np.mean((pred - y_test)**2)
b = model.coef_[0]
a = model.intercept_

# Calculate residuals of test data
residuals = pred - y_test
stat_linjar, p_linjar = sci.shapiro(residuals)

# Use statsmodel for calculating confidens interval
 # Lägg till konstant för intercept
X_train_with_const = sm.add_constant(X_train)
ols_model = sm.OLS(y_train, X_train_with_const).fit()
conf_int_params = ols_model.conf_int(alpha=0.05)

# calculate confidens interval
a_ci = conf_int_params[0]  # Första raden: Intercept
b_ci = conf_int_params[1]  # Andra raden: Lutning

plt.figure(figsize=(10, 6))
# Train data
plt.scatter(X_train, y_train, color="orange", label='Träningsdata', alpha=0.6)
# Test data
plt.scatter(X_test, y_test, color="blue", label='Testdata', alpha=0.6)

# Title
sns.regplot(x=column_name1,
            y=column_name2,
            data=combined_data,
            scatter=False,
```

```
            line_kws={'color': 'red', 'label': f'Y = {a:.2f} + {b:.2f} * X'},
            ci=95)

x_plot = np.linspace(-20, -1, 100).reshape(-1,1)
draw_plot = model.predict(x_plot)

# Regression line for predictions (testdata)
plt.plot(x_plot, draw_plot, color='g', label='Test Data Prediction', linewidth=2)

# show Regression equation and confidence interval
plt.text(0.5, 0.89,
        (f'Lineärmodel: y ={a:.2f} +  {b:.2f}* X\n'
        f'95% konfidens interval för a: [{a_ci[0]:.2f}, {a_ci[1]:.2f}]\n'
        f'95% konfidens interval för b: [{b_ci[0]:.2f}, {b_ci[1]:.2f}]'),
        ha='center',
        va='center',
        transform=plt.gca().transAxes,
        fontsize=10,
        color='red'
        ((f'Shapiro-Wilk test for residualernas spridning: p = {p_linjar:.4f},'
        f'\nstatistics={stat_linjar:.4f}\n'))
        )
plt.title(f'Prognos av luftfuktighet baserat på temperatur i Umeå\n'
        f'Mean squared error: {mse:.2f}\nFraktion: {fraktion}')
plt.xlabel("Temperatur, °C")
plt.ylabel("Relativt Luftfuktighet, %")
plt.legend(loc='best', fontsize=8)
plt.savefig('https://raw.githubusercontent.com/OlganeOlga/MathMod/master/img/regression/
#plt.show()
plt.close()
```

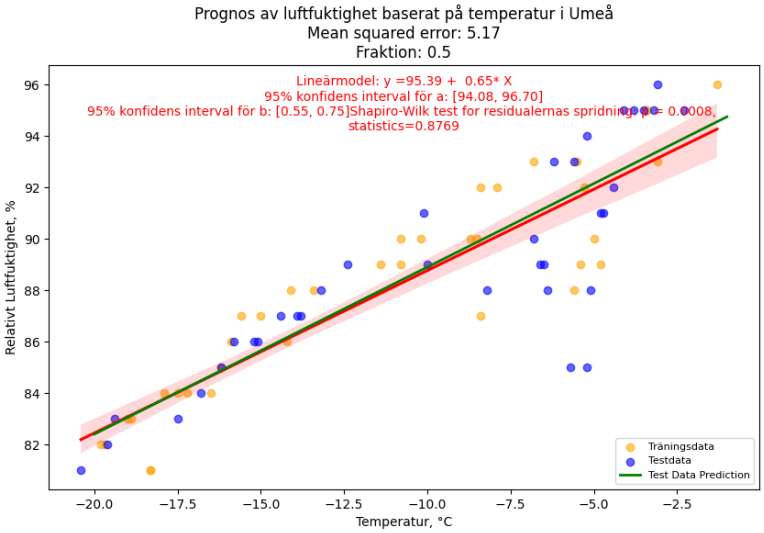

Figur 5a.

Förklaring till figuren 5a. Figuren visar den linjära regressionsmodellen som förutsäger relativ luftfuktighet på Umeå flygplats på grund av temperatur. X-axeln visar temperatur i Celciumgrader, Y-axeln visar relativ luftfuktighet i procent. Orange punkter visar data som använts för att ta fram prediktionsmodellen, blå punkter visar data som använts för att testa prediktionsmodellen. Röd linje representerar prediktionsmodellen och grön linje representerar den modell som skulle erhållas med testdataset. Ekvationen för prediktionsmodellen visas i röd text. Figuren visar den linjära regressionsmodellen som förutsäger relativ luftfuktighet på Umeå flygplats på grund av temperatur. x-axeln visar temperatur i Celciumgrader, y-axeln visar relativ luftfuktighet i procent. Orange punkter visar data som använts för att ta fram prediktionsmodellen, blå punkter visar data som använts för att testa prediktionsmodellen. Röd linje representerar prediktionsmodellen och grön linje representerar den modell som skulle erhållas med testdataset. Ekvationen för prediktionsmodellen, 95% konfedencsintervaler för linjär slop och den fria element, samnt resultat av Shapiro-Wilk test för normalspringding av residualerna, visas i röd text. Grön linja visar korrelation model som skulle skappas om test dataset skulle användas i stället av trainings dataset.

Liniarregression är en linja y = bx + a. I vart fall y föreställer alla data för relativt lyftfuktighet, och x är datarray med temperatyr från respectiva tidspunkter. b kalkuleras som sum((x[i] - medel(x))(y[i] - medel(y)))/sum((x[i]-medel(x))**2) a kalkuleras som medel(y) - b * medel(x) 95% interval kalkulering är korrect ifall residualerna är normalfördelad. Shapiro-Wilk test visar att probabilitet för normalfördelning av resudualer är väldigh litet, bara 0.08% som tilloter förkasta hypotes om normalfördelning av residualer. Det betydet att linjär model inte kan prediktera luftfuktighet på grund av temperatur.

För att skaffa bättre model i detta fall kan jag försöka att ta bort avvikande värde, eller transormera den beroende variable(2). Som det visas på ladogram, finns det inte värde som avviker mycket. Jag väljer därför att transormera den beroende variabel, relativt luftfuktighet.

Uppgift 5: Transformera data

För att se om logmodifiering av relativt luftfuktighet kan hjälpa att skappa bättre model logaritmerar jag dessa värde. Relativtluftfuktighet är alltid positivt, därför modifiering kan göras direkt.

```
# Regression with log relativt humidity
# Relative humidity is always pozitiv
y_train_log = np.log(y_train)
y_test_log = np.log(y_test)

# create liniar regression pf the log data
log_y_model = LinearRegression()
log_y_model.fit(X_train, y_train_log)

# Make prediction of the test data
#x_for_log_y = np.linspace(-1.0, 3.01, 100)
pred_log_y = log_y_model.predict(X_test)
pred_y_by_log = np.exp(pred_log_y)

b_Y_log = log_y_model.coef_[0]
a_Y_log = log_y_model.intercept_

# Create model line use x_plot for prediction
#x_for_log_y = np.linspace(-25,-3, 100)
drow_y_log_model = log_y_model.predict(x_plot)

# Calculate MSE
mse_log_y = np.mean(np.exp(pred_log_y - y_test_log)**2)
print(mse_log_y)
plot_text= ((f'MSE liniarregressoin, original dataset: {mse:.2f}\n'
             f'MSE logtransformerad y, dataset utan avvikande värde: {mse_log_y:.5f}'))


plt.scatter(X_train, y_train_log, label='Träningsdata')
plt.scatter(X_test, y_test_log, label='Test data')
plt.plot(x_plot, drow_y_log_model,
        label='Linjär regression log domän',
        color='g',
        linewidth=3
        )
```

```
plt.legend()
plt.text(-18.5, 4.51,
        f"log(Y) = {a_Y_log:.2f} + {b_Y_log:.2f} * X",
        fontsize=8,
        color="red"
        )
plt.title("Prognos av relativt luftfuktighet (log transformerad y, %)")
plt.xlabel("temperatur, °C")
plt.ylabel("relativt luftfuktighet [log %]")
plt.savefig('https://raw.githubusercontent.com/OlganeOlga/MathMod/master/img/regression/
plt.show()
plt.close()

# Create model line in the original domain
drow_y_log_model_exp = np.exp(log_y_model.predict(x_plot))

# Calculate MSE in original domain
mse_log_y = np.mean((pred_y_by_log - y_test)**2)
# Calculate residualer
residual_log_y = y_test - np.exp(pred_log_y)

p_log_y, stat_log_y = sci.shapiro(residual_log_y)
stderr_log_y = np.std(residual_log_y)
# despersion skattning
n = len(residual_log_y)
mean_x = sum(X_test)/n
residual_variance = sum(r**2 for r in residual_log_y) / (n- 2)
square_sum = sum((X_test[i] - mean_x) ** 2 for i in range(n))[0]
# standard error för koeffitienter
se_b = math.sqrt(residual_variance / square_sum)
# Compute the denominator of the second term (se_a)
sum_squared_diffs = sum((X_test[i] - mean_x) ** 2 for i in range(n))

# Compute the second term in the variance formula
variance_term = mean_x**2 / sum_squared_diffs

# Compute the full variance factor
variance_factor = 1 / n + variance_term

# Compute the standard error
se_a = math.sqrt(residual_variance * variance_factor)

# Plotting
plt.scatter(X_train, y_train, label='Träningsdata (original scale)')
plt.scatter(X_test, y_test, label='Test data (original scale)')
plt.plot(x_plot,
```

```
        drow_y_log_model_exp,
        label='Log-y-transformerad regression i original domän',
        color='g',
        linewidth=3
        )

# t-värde för 95% interval
t_critical = sci.t.ppf(0.975, df=n - 2)
a_error = t_critical * se_a
b_error = t_critical * se_b
plot_text = ((f'y = exp({a_Y_log:.2f} + {b_Y_log:.2f} * X)\n'
        f'Shapiro-Wilk test, p = {p_log_y:.2}\n'
        f'95% konfidencsinterval för a: '
        f'{(a_Y_log - a_error):.2f} < a < '
        f'{(a_Y_log + a_error):.2f}\n'
        f'95% konfidens interval för b: '
        f'{(b_Y_log - b_error):.2f} < b < '
        f'{(b_Y_log + b_error):.2f}')
        )
plt.legend(fontsize=8)
plt.text(-12.5, 81, plot_text, fontsize=8, color='red')
plt.title((f'Prognos av relativt luftfuktighet\n'
        f'model är skapad med logtransformerad y och transformerad tillbacka'))
plt.xlabel("temperatur, °C")
plt.ylabel("relativt luftfuktighet [%]")
plt.savefig('https://raw.githubusercontent.com/OlganeOlga/MathMod/master/img/regression/
plt.show()
plt.close()
```

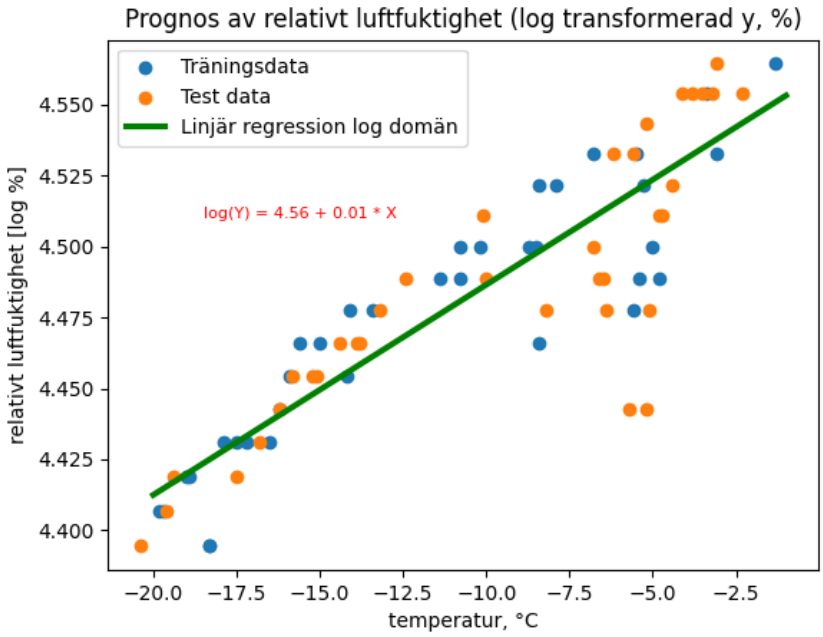

Figur 6a.

Förklaring för Figuren 6a. Figuren visar liniarregression som predikterar logoritm av relativtluftfuktighet på grund av temperatur. X-axel visar temperatur, Y-axel visar logoritmerad relativt luftfuktighet. Ekvationen visas med röd text på plotten

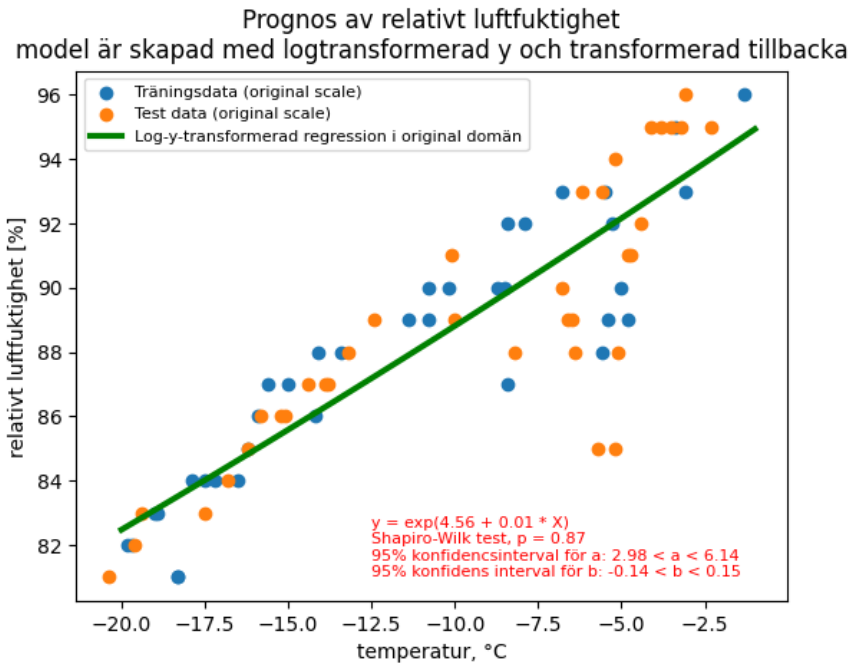

Figur 6b.

Förklaring för Figuren 6b. Figuren visar liniarregression som predikterar logoritm av relativtluftfuktighet på grund av temperatur. X-axel visar temperatur, Y-axel relativt luftfuktighet. Ekvationen visas med röd text på plotten. Det visas också 95% gränser för a och b koefitientar.

För att jamföra modeller skappar jag en plot som visar båda modeller:

```
plt.scatter(X_train, y_train, label='Träningsdata')
plt.scatter(X_test, y_test, label='Test data')
plt.plot(x_plot,
        drow_y_log_model_exp,
        label='Linjär regression exponentiell i log(y)',
        color='green',
        linewidth=3)
plt.plot(x_plot,
        draw_plot,
        label='Linjär regression originela data',
        color="red",
        linewidth=3)
plt.legend()
plot_text= ((f'MSE liniarregressoin, original dataset: {mse:.2f}\n'
            f'MSE logtransformerad y, dataset utan avvikande värde: {mse_log_y:.2f}'))
plt.title("Två modeller i en plot", fontsize=10)
plt.xlabel("temperatur, °C", fontsize=8)
```

```
plt.ylabel("relativt luftfuktighet, %", fontsize=8)
plt.text(-15.0, 80.8, plot_text, color="red", fontsize=8)
plt.savefig('https://raw.githubusercontent.com/OlganeOlga/MathMod/master/img/regression/
plt.show()
```

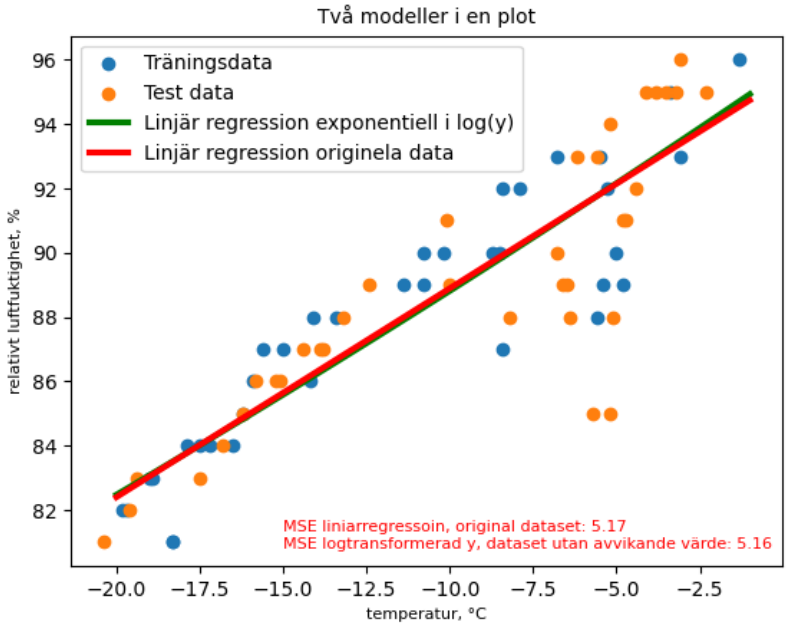

Fig 7.

Förklaring för Figur 7. Figuren visar båda modeller: liniarregression och återtransformerad log-model. Det visas också MSE för båda modeller med röd text.

Sammanfattning

I projektet jag analyserad data från tre meteorologiska stationer i Sverige. Programmen tillåter hämta data och spara de i separata filler. Från filer data kan hämtas för bearbetning.

Jag analyserade temperatur och relativt lyftfuktighet från tre dagar (72 timmar). Jag analyserade fördelningen av data och kom tll slutsats att den liknar inte normalfördelningen. Jag analyserade korrelation mellan olika dataset och kom till slutsats att luftfuktighet för det mesta korrellerar inte liniart med temperatur. Det enda starka korrelation fanns mellan relativt lyftfyúktighet och temperatur i Umeå. Jag skapade två olika regressionsmodeller: direkt liniarregression och liniarregression med logaritmerad relativt lyftfuktighet. Den andra modellen är mera “grundande” eftersom fördelning av residualerna kan räknas som normalt.

Visualisering av modeller visar att de liknar varandra. Däerför kan första modellen anvädndas lika vrå som den andra. Direkt liniar regression kan vara mera preferabel, eftersom den är enklare.

Regressioner med log-transormerade temperaturvärde.

Det är extra del. Temperaturvärde från Umeå är negativa desuttom resultat visade att logoritmisk transformeting av temperatur ledar inte till bättre modelen. Dock jag har utförskat även detta möjlighet.

Eftersom temperatur har negativa värde skjuttar jag alla värde upp, så att de blir högre än null. Jag vär även tvungna att ta bort två mest högsta och två mest lägsta värde. Koden som jag användade:

```
# Log transformation
# I cannot use direct log-transformaton due to negative values of the tempture
# I want to shift all values that the lowest is just above zero
X_combined = combined_data[column_name1].values
# shift all values above zero, 1e-5 ensure that no values are zero
shift_value = abs(X_combined.min()) + 1e-5
def log_stat_plot(x_tr, x_te, y_tr, y_te, name, title=""):
    X_train_log = np.log(x_tr + shift_value)
    X_test_log = np.log(x_te + shift_value)

    # Visualise log transformation
    plt.figure(figsize=(12, 6))
    # Show original data on subplot 1
    plt.subplot(1, 2, 1)
    plt.scatter(x_tr, y_tr, label='Träningsdata')
    plt.scatter(x_te, y_te, label='Test data')
    plt.legend()
    plt.xlabel("Temperatur, °C", fontsize=8)
    plt.ylabel("Relativt luftfuktighet; %", fontsize=8)
    plt.title("Skatterplot med originala x-värde", fontsize=10)

    # Show log transformation on subplot 2
    plt.subplot(1,2,2)
    plt.scatter(X_train_log, y_tr, label='Träningsdata')
    plt.scatter(X_test_log, y_te, label='Test data')
    plt.legend()
    plt.xlabel("Temperatur, log(value - min - 0.00001 )", fontsize=8)
    plt.ylabel("Relativt luftfuktighet; %", fontsize=8)
    plt.title("Skatterplot med log-transformerade x-värde", fontsize=10)
    plt.suptitle(title, fontsize=12)
    plt.savefig(f'https://raw.githubusercontent.com/OlganeOlga/MathMod/master/img/regres
    #plt.show()
    plt.close()
```

```
    return X_train_log, X_test_log
X_train_log, X_test_log = log_stat_plot(x_tr=X_train,
                                        x_te=X_test,
                                        y_tr=y_train,
                                        y_te=y_test,
                                        name='residuals_log_data',
                                        title="Öforändrade data"
                                        )
"""
MODIFY DATASET BY REMOVING OUTLIERS
"""
# Sort the values to identify outliers along axis 0 (values)
X_combined_sotred = np.sort(X_combined, axis=0)

# Create array of values that sould be removed
X_to_remove = X_combined_sotred[:2].tolist() + X_combined_sotred[-2:].tolist()
X_to_remove = set(X_to_remove)
# fined what rows should be removed
rows_to_remove = combined_data[column_name1].apply(
    lambda x: any(np.isclose(x, value) for value in X_to_remove)
    )
# Filter this rows away
filtered_data = combined_data.loc[~rows_to_remove]
train_filt = filtered_data.sample(frac=fraktion, random_state=1)
test_filt = filtered_data.drop(train_filt.index)

# Create new train and test dataset:
X_train_f = train_filt[column_name1].values.reshape(-1, 1)
y_train_f = train_filt[column_name2].values
X_test_f = test_filt[column_name1].values.reshape(-1, 1)
y_test_f = test_filt[column_name2].values
title_n = ("Data utan två tidspunkter med de högsta och\ntva" +
           "tidpunkter med de lägsta temperaturvärde")
X_train_f_log, X_test_f_log = log_stat_plot(X_train_f,
                                            X_test_f,
                                            y_train_f,
                                            y_test_f,
                                            'residuals_log_data_filtered',
                                            title=title_n
                                            )

# Use filtered data to create the regression with log tempture
log_model = LinearRegression()
log_model.fit(X_train_f_log, y_train_f)

log_a = log_model.coef_[0]
```

```
log_b = log_model.intercept_

# Make prediction with test data
pred_log = log_model.predict(X_test_f_log)

x_log = np.linspace(-1.0, 3.01, 100)
draw_x_log_model = log_model.predict(x_log.reshape(-1, 1))

# Calculate MSE for logarithmik transformation
mse_log = np.mean((pred_log - y_test_f)**2)

# Transform predictions back to the original scale
pred_original = np.exp(pred_log) - shift_value

# Calculate MSE in the original domain
mse_original = np.mean((pred_original - X_test_f)**2)

# Show prediktions
plt.scatter(X_train_f_log, y_train_f, label='Träningsdata')
plt.scatter(X_test_f_log, y_test_f, label='Test data')
plt.plot(x_log,
        draw_x_log_model,
        label='Linjär regression,
        log transformerad i x',
        color='c',
        linewidth=3)
plt.text(-0.7,
         90.0,
         f'y = {log_a:.2f} + {log_b:.2f}*log(x)',
         fontsize=8,
         color="r")
plt.legend()
plt.title((f'Prognos av relativt luftfuktighet med logaritmisk model '
           f'(x är log transformerad)'),
           fontsize=10)
plt.xlabel("log(temperatur - min(temperatur) + 0.00001, °C)", fontsize=8)
plt.ylabel("Relativt luftfuktighet, %", fontsize=8)
plt.savefig('https://raw.githubusercontent.com/OlganeOlga/MathMod/master/img/regression/
#plt.show()
plt.close()

# Calculate residuals of test data
residual = y_test_f - pred_log
# this array contain nan becouse of previouse manipulations with data
# I want to remove nan elements:
data_without_nan = [x for x in residual if not math.isnan(x)]
```

```
std_residual = np.std(data_without_nan)
# Show residuals of the test data
plt.scatter(X_test_f, residual)
plt.axhline(0, color='r', linestyle='--')
plt.title("Logmodel predictions residulaer av luftfuktighet vid Umeå flygplats")
plt.xlabel("trelativt luftfuktighet,  %")
plt.ylabel("Residualer, %")
plt.savefig('https://raw.githubusercontent.com/OlganeOlga/MathMod/master/img/regression/
#plt.show()
plt.close()

# Show histogram of the residuals of the test data
plt.hist(residual, bins=10)
plt.title("Residualernas histogram för logoritmisk model av luftfuktighet vid Umeå",
            fontsize=10)
plt.xlabel("Residualer av luftfuktighet, %")
plt.ylabel("Frekvens")
plt.savefig(''regression/residuals_filtrerad_hist_LOGtemp_fukt_UME.png')
#plt.show()
plt.close()

"""_summary_
"""
# get liniar model with the modyfiyed data:
# Trainings model
lin_model_f = LinearRegression().fit(X_train_f, y_train_f)
lin_pred_f = model.predict(X_test_f)

# MSE of test data
mse_lin_f = np.mean((lin_pred_f - y_test_f) ** 2)
# Transform back model

plt.scatter(X_train, y_train, label='Träningsdata')
plt.scatter(X_test, y_test, label='Test data')
plt.plot(x_plot,
         drow_y_log_model_exp,
         label='Linjär regression exponentiell i log(y)',
         color='green',
         linewidth=3)
plt.plot(x_plot,
         draw_plot,
         label='Linjär regression originela data',
         color="red",
         linewidth=3)
#plt.plot(np.exp(x_log) - shift_value,
         draw_x_log_model,
```

```
         label='Linjär regression,
         exponentiell i x',
         color='c',
         linewidth=3)
plt.legend()
plot_text= (f'MSE liniarregressoin, original dataset: {mse:.2f}\n'
        f'MSE logtransformerad y, dataset utan avvikande värde: {mse_log_y:.2f}')
plt.title("Två modeller i en plot", fontsize=10)
plt.xlabel("temperatur, °C", fontsize=8)
plt.ylabel("relativt luftfuktighet, %", fontsize=8)
plt.text(-15.0, 80.8, plot_text, color="red", fontsize=8)
plt.savefig(''regression/tva_modeller.png')
plt.show()
plt.close()

"""
Y_LOG
"""
# Regression with log relativt humidity
# Relative humidity is always pozitiv
y_train_log = np.log(y_train_f)
y_test_log = np.log(y_test_f)

# create liniar regression pf the log data
log_y_model = LinearRegression()
log_y_model.fit(X_train_f, y_train_log)

# Make prediction of the test data
#x_for_log_y = np.linspace(-1.0, 3.01, 100)
pred_log_y = log_y_model.predict(X_test_f)
pred_y_by_log = np.exp(pred_log_y)

b_Y_log = log_y_model.coef_[0]
a_Y_log = log_y_model.intercept_

# Create model line use x_plot for prediction
#x_for_log_y = np.linspace(-25,-3, 100)
drow_y_log_model = log_y_model.predict(x_plot)

# Calculate MSE
mse_log_y = np.mean((np.exp(pred_log_y) - y_test_f)**2)
plot_text= (f'MSE liniarregressoin, original dataset: {mse:.2f}\n'
            f'MSE liniarregressoin, dataset utan avvikande värde: {mse_lin_f:.2f}\n'
            f'MSE logtransformerad x, dataset utan avvikande värde: {mse_log:.2f}\n'
            f'MSE logtransformerad y, dataset utan avvikande värde: {mse_log_y:.5f}')
```

```
plt.scatter(X_train_f, y_train_log, label='Träningsdata')
plt.scatter(X_test_f, y_test_log, label='Test data')
plt.plot(x_plot,
         drow_y_log_model,
         label='Linjär regression log domän',
         color='g',
         linewidth=3)
plt.legend()
plt.text(-18.5,
         4.51,
         f'log(Y) = {a_Y_log:.2f} + {b_Y_log:.2f} * X',
         fontsize=8,
         color="red")
plt.title("Prognos av relativt luftfuktighet (log transformerad y, %)")
plt.xlabel("temperatur, °C")
plt.ylabel("relativt luftfuktighet [log %]")
plt.savefig(''regression/log_transform_FUKT_Umeå.png')
plt.show()
plt.close()

# Create model line in the original domain
drow_y_log_model_exp = np.exp(log_y_model.predict(x_plot))

# Calculate MSE in original domain
mse_log_y = np.mean((pred_y_by_log - y_test_f)**2)
# Calculate residualer
residual_log_y = y_test_f - np.exp(pred_log_y)

p_log_y, stat_log_y = sci.shapiro(residual_log_y)

# Plotting
plt.scatter(X_train_f, y_train_f, label='Träningsdata (original scale)')
plt.scatter(X_test_f, y_test_f, label='Test data (original scale)')
plt.plot(x_plot,
         drow_y_log_model_exp,
         label='Log-y-transformerad regression i original domän',
         color='g',
         linewidth=3)

plt.legend(fontsize=8)
plt.text(-20,
         92,
         f'y = exp({a_Y_log:.2f} + {b_Y_log:.2f} * X)',
         fontsize=8,
         color="red")
```

```
plt.title(f'Prognos av relativt luftfuktighet\n'
          f'model är skapad med logtransformerad y och transformerad tillbacka')
plt.xlabel("temperatur, °C")
plt.ylabel("relativt luftfuktighet [%]")
plt.savefig(''regression/back_log_transform_FUKT_Umeå.png')
plt.show()
plt.close()

#TREE MODELS ON ONE PLOT
plt.scatter(X_train, y_train, label='Träningsdata')
plt.scatter(X_test, y_test, label='Test data')
plt.plot(x_plot,
         drow_y_log_model_exp,
         label='Linjär regression exponentiell i y',
         color='orange',
         linewidth=3)
plt.plot(np.exp(x_log) - shift_value,
         draw_x_log_model,
         label='Linjär regression,
         exponentiell i x',
         color='red',
         linewidth=3)
plt.plot(x_plot,
         draw_plot,
         color='green',
         label='Test Data Prediction',
         linewidth=2)
plt.text(-20, 94, plot_text, fontsize=8, color="red")
plt.title("Prognos av relativt luftfuktighet med alla modeller")
plt.ylabel("Relativt lutfuktighet %")
plt.xlabel("Temperatur, °C")
plt.legend(loc='best', frameon=True, fontsize=8)
plt.tight_layout()
plt.savefig(''regression/alla_modeller_Umeå.png')
plt.show()
plt.close()
```

Sammanfattande esultat av transformationer visas på följande plot: #### Figur 8 Tre modeller med transformerade data utan data som innehåller två högsta och två lägsta temperaturvärde ##### Förklaring till Figur 8. Figur visar tre modeller som predikterar relativt luftfuktighet med temperatur i Umeå Flugplats. För alla tre modeller användes 68 mätpunkter (data utan två högsta temperaturvärde och två lägsta temperatur vrde). Liniarregression visas med grön linjen, model skaffade med log-transformerade luftfuktighetsvärde visas som grön linja och model skaffad med logtransformerade temperaturvärde visas som en röd linja. MSQ för alla modeller visas med röd text. Första MSE

värde kommer från liniarregressions modellen som var skaffad på grun av original dataset. Det är tydligt att logoritmisk transformation av temperaturvärde hjälper inte skaffa bättre modellen. MSE från sisnämnda modelen är betydligh högre än MSE från två andra modller.

Referencer:

1. Wilk, M. B., & Gnanadesikan, R. (1968). Probability plotting methods for the analysis of data. Biometrika, 55(1), 1–17.
2. Osborne, J., (2002) "Notes on the use of data transformations", Practical Assessment, Research, and Evaluation 8(1): 6. doi: https://doi.org/10.7275/4vng-5608